




fMRI 数据处理方法



fMRI 的理论与技术问题





内容:

fMRI的原理

fMRI的数据处理方法

PCA

ICA

CA





History of Magnetic Resonance

- 1946 NMR *Purcell and Bloch*
Physics, Chemistry, Biology
- 1973 MRI *Lauterbur and Mansfield*
Radiology
- 1990 fMRI *Belliveau, Ogawa, and Kwong*
Neuroscience



First MRI image



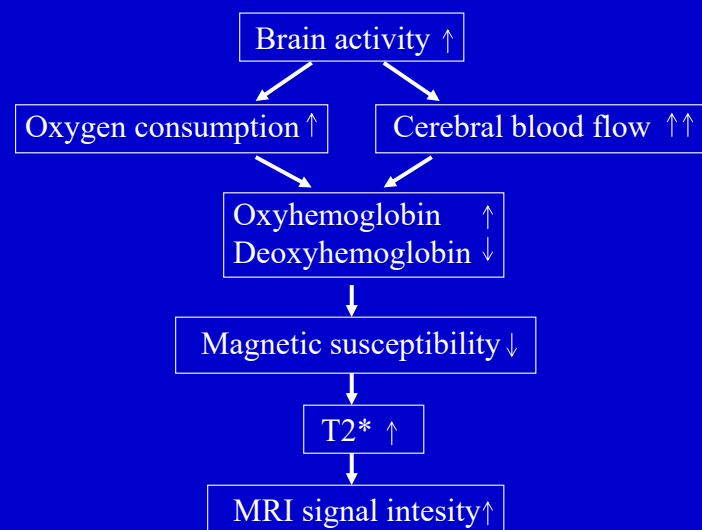
Lauterbur, *Nature*, 1973

Research Imaging Center

UT Health Science Center

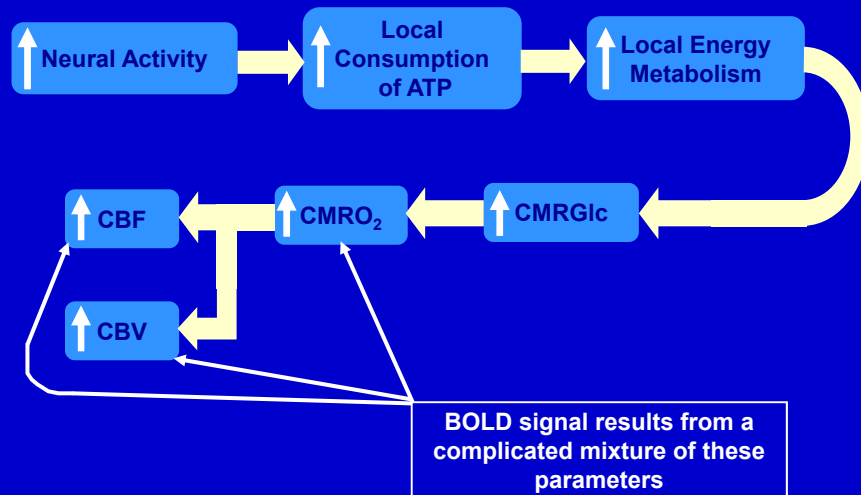


Mechanism of BOLD Functional MRI






From A Physiology POV




Non-linearity of BOLD Response

BOLD response vs. length of stimulation




BOLD response during rapidly-repeated stimulation






Experimental Designs in fMRI



Block-Design fMRI



Event-Related fMRI



Time Series and Activation Maps





fMRI 数据处理方法

背景:

数据驱动 (data-driven): PCA, ICA, FCA 等

模型驱动 (model-driven): 相关法

广义线性模型



一. 主成分分析 (PCA, principle component analysis)

假设fMRI的数据为data, 那么它的协方差:

$$R = data^T \times data$$

对协方差矩阵R进行奇异值分解:

$$[u, d, v] = \text{SVD}(R)$$

其中, u和v分别是特征向量, d是对角线为A阵奇异值的
对角阵, 且奇异值是按从大到小的顺序排列的。



一. 主成分分析 (PCA)

把原数据向特征空间投影，得到原数据data的主成分

$PCA = data * U(:, 1)$

若需要取原数据A的前k个主成分，则

$PCA = data * U(:, 1:k)$

投影到原始数据

$Data' = data * U(:, 1:k) * U(:, 1:k)'$



一. 主成分分析 (PCA)

如果需要计算这k个主成分在原数据中的所占比例，即k个主成分的累计方差贡献率，则 η_k

$$\eta_k = \sum_{i=1}^k d_{ii} / \sum_{i=1}^p d_{ii}$$

通常当 $\eta_k > 90\%$ 时，可以确定保留这k个主成分比较合适，而其余的主成分则可以略去。



主成分分析 (PCA) 应用

(1). 特征值

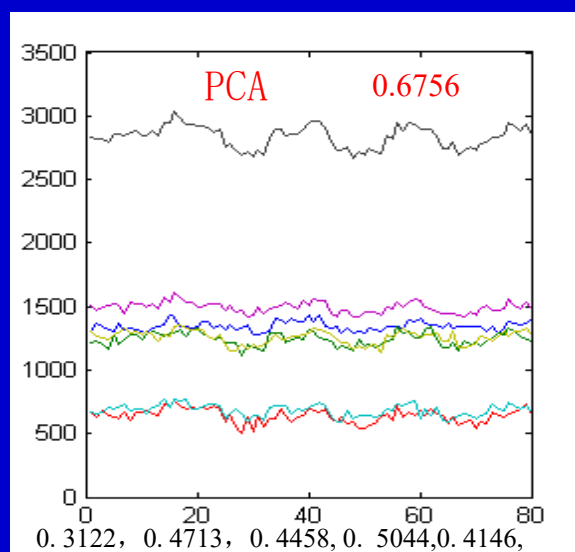
```
PCA= data*U(:,1)
```

(2). 去伪迹

```
PCA= data*U(:,3:32)
```




(1). 特征值






(2).去伪迹




noise EEG
signal




PCA result




PCA fMRI应用(癫痫病胶质瘤) lipoma epilepsy




结构MRI




SPM-ICA-PCA结果






Delay PCA结果



结构MRI



SPM-ICA-PCA结果



Delay PCA结果



二. 独立成分分析 (ICA independent component analysis)

背景: $X=AS$

ICA的目的是: 在未知A的情况下, 根据观测数据X去发现未知的统计独立的源信号S。

开始: 1990

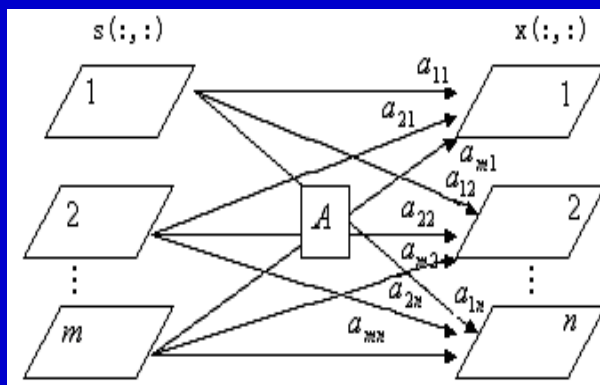
代表: P. Com (1994)

A. Hyvarinen (1999, 2000)



1. ICA模型

设无噪声信号模型为 $X=As$



A 为信号混合矩阵, x 是 N 维观测信号向量, s 是 M ($N>M$) 维原始信号向量。



由 (1) 可见, 信号 S 放大 k 倍与 A 的相应列缩小 k 倍的结果相同, 从而决定了 ICA 得到的信号存在强度的不确定性。为此, 在求解时往往把观测信号先转化为有单位协方差的信号, 即在 ICA 之前先有一个白化过程^[2]。

设信号向量 y 的联合概率密度为 $p(y)$, 而每一个信号成分的概率密度为 $p(y_i)$, 则信号向量的互信息可以表示为:

$$I(y) = \int p(y) \log \frac{p(y)}{\prod_{i=1}^M p_i(y_i)} dy \quad (2)$$

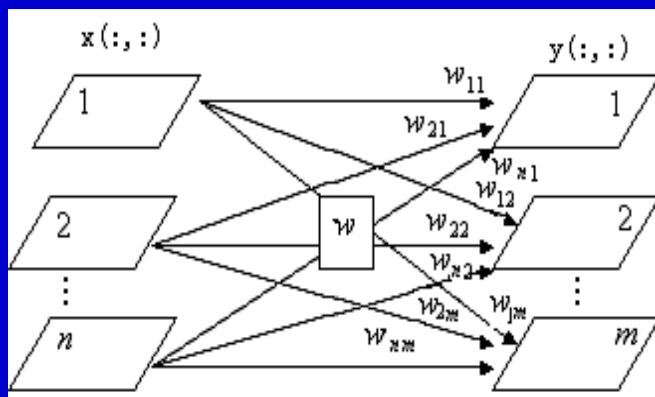
当各个信号成份相互独立时, $p(y) = \prod_{i=1}^M p(y_i)$

则 $I(y) = 0$ 。 (3)




ICA的目的是：在我们不知道混合矩阵的情况下，寻找线性映射 w ，从观测信号中提取不能被直接观测的原信号，这里把它记为：

$$y=wx=wAs \quad (4)$$



2. ICA算法仿真实例：



原始信号

混合信号

ICA 分离信号



ICA分离图像仿真实验



原始图像



混合图像



ICA分离图像




3. 独立成分分析(ICA)应用

(1) EEG 脑电信号


(2) fMRI 信号



(1) EEG 脑电信号



癫痫EEG
数据



ICA分
离成
份



(2) ICA-fMRI数据处理模型

空间ICA-fMRI: 信号与噪声的空域分布相互独立

时间ICA-fMRI: 信号与噪声的时间过程相互独立



1) ICA-fMRI数据模型

$$X = AS$$


$s = \{s_1, s_2, \dots, s_N\}$ 是N个相互独立的fMRI源信号

$x = \{x_1, x_2, \dots, x_M\}$ 是M个观测的fMRI数据。

A 是 $M \times N$ 维的未知的不变混合矩阵

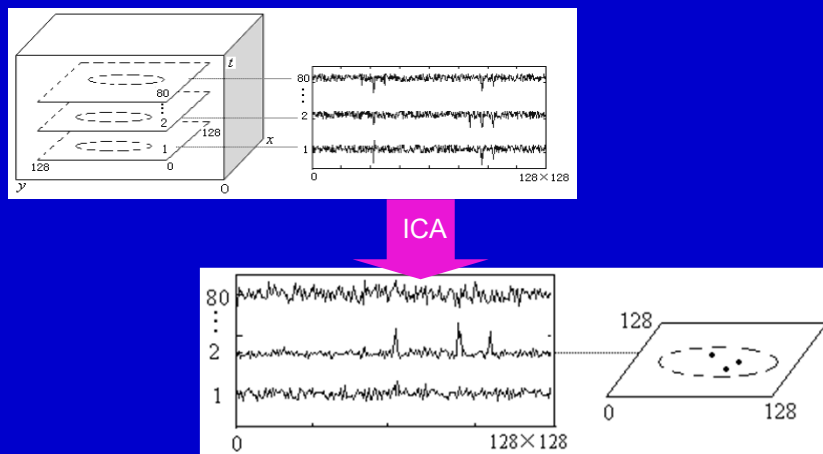


2) 空间ICA的算法示意图(一)





2) 空间ICA的算法示意图(二)




应用研究

空间ICA的分离结果

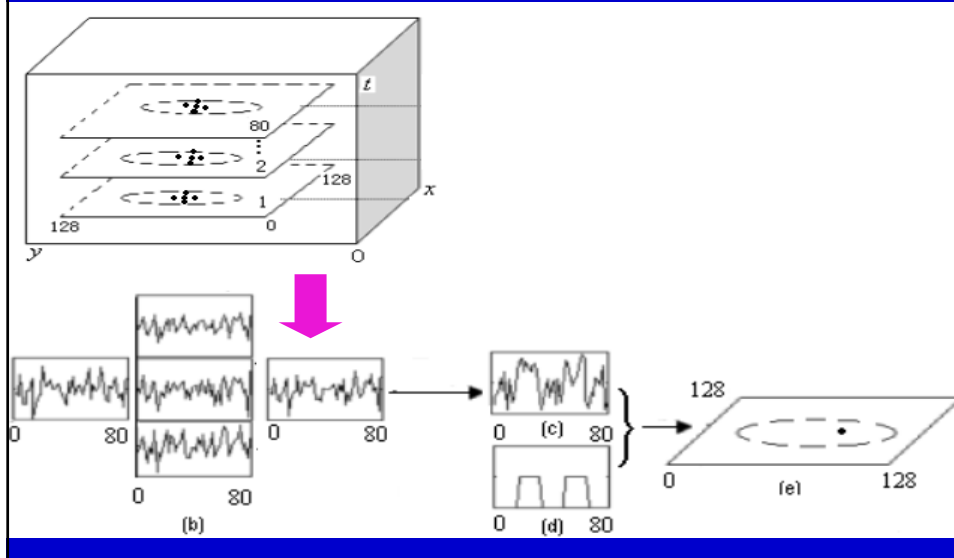


空间ICA组合结果






3) 邻域时间ICA-fMRI模型




应用研究


时间ICA的结果



阈值0.55



阈值0.50





三. 聚类fMRI方法



聚类分析法是理想的多变量统计技术.

基本思想：我们所研究的样品或变量之间存在程度不同的相似性（亲疏关系——以样品间距离衡量）。于是根据一批样品的多个观测指标，具体找出一些能够度量样品或指标之间相似程度的统计量，以这些统计量为划分类型的依据。把一些相似程度较大的样品（或指标）聚合为一类，把另外一些彼此之间相似程度较大的样品（或指标）又聚合为另一类，直到把所有的样品（或指标）聚合完毕。



三. 聚类fMRI方法

聚类的方法有：
直接聚类法；
最短距离聚类法；
最远距离聚类法；






三. 聚类fMRI方法

邻域相关 预处理 压缩数据

提出新的 综合时-空域信息的 距离度量


$$d_{ST} = (1 - \text{corr}(v_i, v_j)) * e^{(|x_i - x_j| + |y_i - y_j|)}$$




原始fMRI图象序列

邻域相关

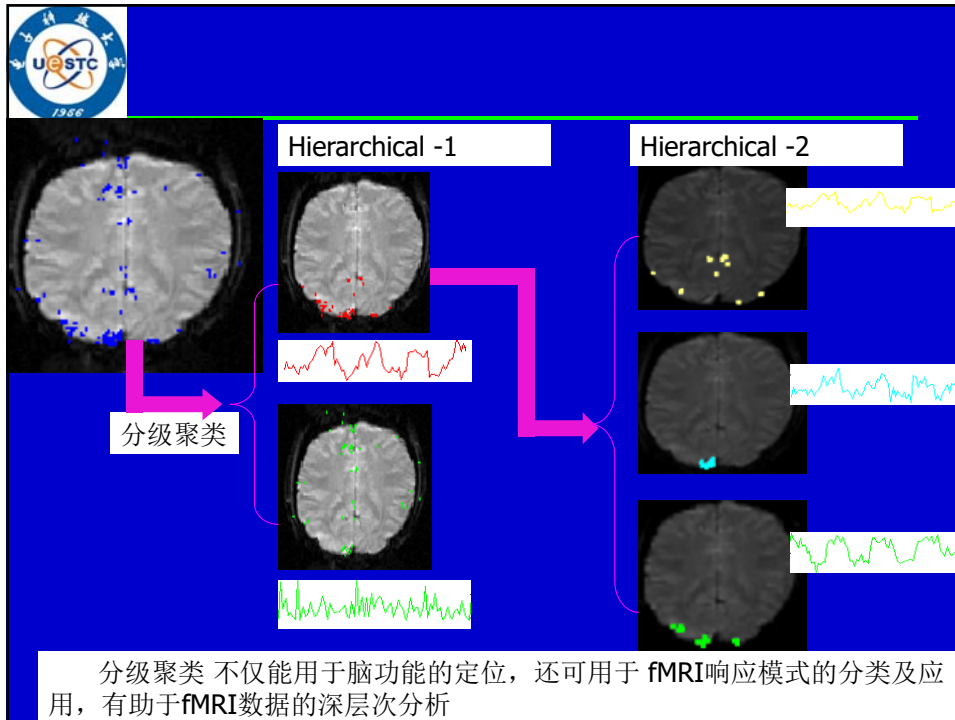
可能的兴奋点



Visual fMRI Data



分级聚类



USTC 1956

Thank You for your attention